

# Máxima Verosimilitud

*Creado: Agosto 2024*

---

## Cobb-Douglas

Se tiene una función de producción ( $Q_i$ ) dependiente de trabajo ( $L_i$ ) y capital ( $K_i$ ) de la forma Cobb-Douglas asumiendo un error multiplicativo log-normal y homocedástico.

$$Q_i = \beta_0 L_i^{\beta_1} K_i^{\beta_2} \epsilon_i$$

## Repaso distribución log-normal

Se tiene una media ( $m$ ) y una varianza ( $v$ ):

$$m = \exp\left(\mu + \frac{\sigma^2}{2}\right)$$

$$v = \exp(2\mu + \sigma^2) (\exp(\sigma^2) - 1)$$

Puede calcular los parámetros de distribución lognormal  $\mu$  y  $\sigma$  a partir de la media  $m$  y la varianza  $v$ :

$$\mu = \log\left(\frac{m^2}{\sqrt{v + m^2}}\right)$$

$$\sigma = \sqrt{\log\left(\frac{v}{m^2} + 1\right)}$$

## Función de densidad de probabilidad

$$y = f(x \mid \mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left\{-\frac{(\log x - \mu)^2}{2\sigma^2}\right\}, \quad \text{for } x > 0.$$

Fuente: [MATLAB](#)

## Máxima Verosimilitud en STATA

En nuestro caso  $\epsilon_i \sim \text{LN}(0, \sigma^2)$

En STATA crearemos el programa "**cobbdouglas\_mv**", definimos su versión, y los "**args**" a usar, en este caso:

- "**lnf**" indica que es una función de logverosimilitud  $\ln(\beta_0) + \beta_1 \ln(L_i) + \beta_2 \ln(K_i)$
- "**mu**" puede tener otro nombre, en este momento señala que la combinación especificada es la media.
- "**sigma**" es la desviación estándar del error.

Finalmente, se plantea la relación que van a tener los argumentos. Ahora se calcula el logaritmo de las variables y se plantea el modelo con **ml**.

### Estimar el modelo

En **ml model** se especifica el modelo, **lf** especifica que el contexto es de forma lineal, luego se definen las variables y un paréntesis vacío indicando error homocedástico. Ahora, con **ml max** se estima el modelo.

En los resultados se obtienen los coeficientes (Betas) en la sección **eq1**. En **eq2** se obtiene la varianza ( $\sigma^2$ ) del error  $\epsilon_i$ . Note que los coeficientes de trabajo y capital no suman 1 y podemos plantear la hipótesis nula de que la función de producción presenta rendimientos constantes a escala con la prueba de *razón de verosimilitud*.

Para esto se impone una restricción con el comando **constraint** señalando que la suma de los coeficientes es igual a 1. En ambos modelos se guardan los resultados bajo los nombres **m1** y **m2**.


## Testeando los resultados

### Razón de verosimilitud

Simplemente debemos correr **lrtest m1 m2**. Con un p-value muy bajo rechazamos la hipótesis nula de rendimientos constantes a escala a todos los niveles de significancia.

### Wald

Se llega al mismo resultado con un simple **test** que compare los resultados del modelo sin restricción.



## Especificación del Modelo con Error Aditivo

En el modelo anterior el término error multiplica a la regresión, esto puede no ser del todo apropiado porque asume que la variabilidad o el "ruido" en los datos es proporcional al valor de la regresión. Ahora se plantea lo siguiente:

$$Q_i = \beta_0 L_i^{\beta_1} K_i^{\beta_2} + \epsilon_i \quad \text{con} \quad \epsilon_i \sim N(0, \sigma^2)$$

Despejando el error se tiene:

$$\epsilon_i = Q_i - \beta_0 L_i^{\beta_1} K_i^{\beta_2} = Q_i - \beta_0 \exp\{\beta_1 \ln(L_i) + \beta_2 \ln(K_i)\}$$

El proceso es muy similar, se crea un programa nuevo, indica versión y sus **args**, lo diferente es que ahora se agrega el factor tecnología **b0** y los demas factores ponderados **b1x**, note que los residuos (**res**) son iguales a la diferencia de la regresión y estos residuos se distribuyen de manera normal.

## Repaso distribución normal

Los estimadores de máxima verosimilitud de  $\mu$  y  $\sigma^2$  para la distribución normal, respectivamente, son:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$s_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad (\text{insesgado})$$

## Función de densidad de probabilidad

$$y = f(x \mid \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \text{para } x \in \mathbb{R}.$$

## Log-Verosimilitud

La log-verosimilitud,  $\ln L$ , es el logaritmo natural de la función de verosimilitud. Para  $n$  observaciones independientes, la log-verosimilitud de los datos bajo este modelo normal es la suma de los logaritmos de las densidades de probabilidad:

$$\ln L(\mu, \sigma) = \sum_{i=1}^n \ln \left( \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left( -\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right)$$

Desglosando esta expresión:

$$\begin{aligned} & \sum_{i=1}^n \ln \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \left( -\frac{(x_i - \mu_i)^2}{2\sigma^2} \right) \\ \Rightarrow & \sum_{i=1}^n (\ln(1) - \ln(\sqrt{2\pi\sigma^2})) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma) \\ \therefore & \ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned}$$

## Caso un único error

$$\epsilon \sim N(0, \sigma^2)$$

$$f(e) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{\epsilon^2}{2\sigma^2} \right)$$

$$\ln L = \ln \left( \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{\epsilon^2}{2\sigma^2} \right) \right)$$

$$\ln L = \ln \left( \frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{\epsilon^2}{2\sigma^2}$$

Por lo tanto, la función de log-verosimilitud completa se convierte en:

$$\ln L = -\frac{1}{2} \ln(2\pi) - \ln(\sigma) - \frac{\epsilon^2}{2\sigma^2}$$

Esta función permitirá comparar diferentes funciones **log-likelihood** en STATA, por lo tanto las incluimos en el **program** de la forma:

$$-0.5*\ln(2*\pi)-\ln(\sigma)-0.5*\text{res}'^2/\sigma^2$$

Finalmente ejecutamos el modelo "maximum likelihood" **ml model lf cobb Douglas2 (b1: Q=ln\_L ln\_K, nocons) (b0:) (sigma:)**

Finalmente realizamos los mismos tests que en modelo anterior.

# Ejemplo de estimación de máxima verosimilitud a mano

FDP exponencial:

$$y = f(x \mid \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$$

## Paso 1: Multiplicatoria

La función de verosimilitud  $L(\theta)$  para una muestra de tamaño  $n$  es el producto de las funciones de densidad individuales:

$$L(\theta) = \prod_{i=1}^n f(x_i \mid \theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}}$$

## Paso 2: Log-Verosimilitud

Tomamos el logaritmo natural de la función de verosimilitud para obtener la función de log-verosimilitud ( $\ell(\theta)$ ):

$$\ell(\theta) = \ln L(\theta) = \ln \left( \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}} \right)$$

$$\ell(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n x_i$$

## Paso 3: Derivada de la Log-Verosimilitud

Para encontrar el MLE, derivamos  $\ell(\theta)$  con respecto a  $\theta$  e igualamos a cero:

$$\frac{\partial \ell(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i$$

$$\frac{\partial \ell(\theta)}{\partial \theta} = 0 \implies -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0$$

## Paso 4: Resolución para el Estimador de Máxima Verosimilitud

Resolviendo la ecuación anterior para  $\theta$ :

$$-\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0$$

Multiplicamos ambos lados por  $\theta^2$ :

$$-n\theta + \sum_{i=1}^n x_i = 0$$

Por lo tanto, el estimador de máxima verosimilitud para  $\theta$  es:

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$